

XVA and its Greeks Calculation

森本 裕介

三菱 UFJ 銀行

2018/11/23 - 11/25

数理ファイナンス合宿セミナー

Contents

- Definition of XVA
- Calculation of XVA
- Greeks calculation of XVA

Definition of XVA

- V : 従来のデリバティブの価値
 - Counter party risk(自社のクレジットリスク) を考慮しない
 - 担保を勘案しない (Variation margin, Initial Margin)
 - 自社の Funding コストを考慮しない
- \hat{V} : 上記に付随する金利のスプレッド, Cash flow を勘案したデリバティブの価値

$$\hat{V} = V + \sum_{X=C,D,F,M,\dots} XVA$$

- CVA: counterparty credit risk adjustment
- DVA: Own credit risk adjustment
- FVA: Funding cost
- MVA: Margin cost

\hat{V} の導出には色々なやり方があり、それに応じて XVA の表現にも色々な流派がある。そもそも、XVA の分け方は当然色々なものがあり、各社マネージのしやすさに応じて自社独自のコストの仕分けを行なっている。

- Piterburg
- Burgard and Kjaer
- Albanese and Andersen
- Fuji and Takahashi
- Takada

Semi-Replication Theory

Burgard-Kjaer

- S : Spot asset price $dS = \mu(t, S)Sdt + \sigma_s S dW_s$
- r : risk free rate $dr = \mu_r(t, r)dt + \sigma_r(t, r)dW_r$
- P_r : default free bond : $dP_r = r dP_r dt$
- P_c, P_F : counterparty and bank bond

$$dP_* = r_* P_*(t-)dt - (1 - R_*)P_*(t-)dJ_*, * = c, F$$

- β_* : repo account $d\beta_* = r_* \beta_* dt, * = S, r, c, F$
- $r_* = r + s_*$, $s_* = (1 - R_*)\lambda_*$, $* = c, F$
- $C = C_v + C_i$: collateral (Variation margin, initial margin)

Bank **から見た** Derivative **の価値** \hat{V}

$$\hat{V} = \hat{V}(t, r, S, J_F, J_c),$$

$$\hat{V}(T, r, S, 0, 0) = H(r, S),$$

$$\hat{V}(t, R, S, 1, 0) = g_F, \hat{V}(t, R, S, 0, 1) = g_c.$$

Hedging portfolio value Π

$$\Pi = \delta_s S + \delta_c P_c + \delta_r P_r + \delta_F P_F + \alpha_s \beta_s + \alpha_c \beta_c + \alpha_r \beta_r - C,$$

$$\Pi = \hat{V}.$$

Hedge asset **の** Repo **調達を仮定**

$$\delta_s S + \alpha_s \beta_s = 0,$$

$$\delta_c P_c + \alpha_c \beta_c = 0,$$

$$\delta_r P_r + \alpha_r \beta_r = 0.$$

Funding condition

$$\hat{V} + \delta_F P_F - C = 0.$$

Semi-Replication 1: 自社の default risk 意外を全て hedge

$$\begin{aligned}
 & d(\hat{V} + \Pi) \\
 = & \left\{ \left(\frac{\partial}{\partial t} + \mathcal{A} \right) \hat{V} + r_F \delta_F P_F + \lambda_c (g_c - \hat{V}) - r_v C_v - r_i C_i \right\} dt \\
 & + \epsilon_h dJ_B
 \end{aligned}$$

$$\hat{V} = V_{c_v} + CVA + FVA + MVA$$

$$CVA = -E \left[\int_0^T \lambda_c(t) D^{r_F + \lambda_c} (V_{c_v} - g_c) dt \right]$$

$$FVA = -E \left[\int_0^T (r_F - r_{c_v}) D^{r_F + \lambda_c} (V_{c_v} - g_c) dt \right]$$

$$MVA = -E \left[\int_0^T (r_F - r_{c_i}) D^{r_F + \lambda_c} C_i dt \right]$$

FVA は自社の default risk を完全に hedge できないことから出てくる

$$FVA = DVA + FCA,$$

$$DVA = -E\left[\int_0^T \lambda_B(t) D^{r_F + \lambda_c}(V_{c_v} - g_B) dt\right]$$

$$FCA = -E\left[\int_0^T \lambda_B(t) D^{r_F + \lambda_c} \epsilon_h(t) dt\right].$$

FVA に関する様々な議論 (Hull, White, Albanese, Andersen, Crepy, Duffie, etc.)

- Pricing は Funding と切り離して行われるべきだ
- Modigliani-Millar の定理: 企業価値は Funding strategy に依存しない に矛盾
- Shareholder value, Firm Value

Semi-Replication 2 : Martingale Part 以外をすべて hedge

$$\begin{aligned}
&= \left\{ \left(\frac{\partial}{\partial t} + \mathcal{A} - r \right) \hat{V} + \lambda_B (g_B - \hat{V}) + \lambda_c (g_c - \hat{V}) \right. \\
&\quad \left. + (r - r_v) C_v + (r - r_i) C_i \right\} dt \\
&\quad + \epsilon_h (dJ_B - \lambda_B dt).
\end{aligned}$$

$$\hat{V} = V_{c_v} + CVA + DVA + VMVA + VMVA + IMVA$$

$$CVA = -E \left[\int_0^T \lambda_c(t) D^{r+\lambda_B+\lambda_c} (V_{c_v} - g_c) dt \right]$$

$$DVA = -E \left[\int_0^T \lambda_B(t) D^{r+\lambda_B+\lambda_c} (V_{c_v} - g_B) dt \right]$$

$$VMVA = -E \left[\int_0^T (r - r_{c_v}) D^{r+\lambda_B+\lambda_c} (V_{c_v} - C_v) dt \right]$$

$$IMVA = -E \left[\int_0^T (r - r_{c_i}) D^{r+\lambda_B+\lambda_c} C_i dt \right]$$

XVA の計算法

- Counterparty c に対する XVA は概ね以下のような計算になる.

$$\text{XVA}(c) = \sum_{j=1}^J E \left[\int_0^T Z(t) \left(\sum_{k \in N_j(c)} V_k(t) - C(t) \right)^{(+)} dt \right]$$

- $V_k(t)$: 取引 k の Exposure(t 時点の時価)

$$V_k(t) = E \left[\sum_{t_i > t} F_k(t_i, X(t_i)) | \mathcal{F}_t \right]$$

- $N_j(c)$: c との取引契約はいくつかの Netting Set(CSA 条件などによって) に分かれている。

$$\text{Trade}(c) = \cup_{j=1}^J N_j(c)$$

- Z : discount, spread, hazard, recovery rate, etc.
- T : $\text{Trade}(c)$ に含まれる取引の最長満期

実際の計算は大きく 2 つに大別される。

- Approximate Exposure function

V_k を原資産の関数として、その関数系を計算する。

$$\tilde{V}_k : \mathbf{R}^N \rightarrow \mathbf{R},$$

$$V_k(t) \approx \tilde{V}_k(X(t))$$

- Aggregation

- $\tilde{V}_k(X(t))$ から、Collateral \tilde{C} を計算.
- collateral 勘案後の Exposure に spread をかけて積分を実施.

$$E \left[\int_0^T \left(\tilde{V}_k(X(t)) - \tilde{C}(t) \right) D(t) dt \right].$$

Collateral 計算法

- VM(Variation Margin)
 - H : Threshold. Exposure **がこの額を超えていないと担保なし。**
 - M : MTA(minimum transfer amount). **支払い担保の最低額。**
 - δ : MPOR(mergin period of risk). Default **時点と最後に担保が支払われた時点のバッファ期間。** e.g. 14day.

$$C(t) = (V(t - \delta) - H)^+ 1_{\{V(t-\delta)-H > M\}}$$

- IM(Initial Margin)
 - MPOR **期間の Gap Risk をカバーする。** e.g. 10day 99% Var.
 - CCP(central counter party) や、SIMM(standard initial margin model) **ごとに Greeks を使った Var の近似公式が決められている。**

$$IM(t) = \sum \phi_{i,j} \frac{\partial V(t)}{\partial X^i(t)} \frac{\partial V(t)}{\partial X^j(t)}$$

XVA の数値計算手法

- 大量の risk factor, product の計算を同時に行う必要があるため (Netting), Monte-Carlo 法が通常使われる。
- Exposure 計算には American Monte Carlo 法が使われる。多くの場合、LSM(Least square monte carlo) が用いられる。

$$\tilde{V}(x) = \sum_{i=1}^n a_i \phi_i(x), \quad \phi_i : \text{polynomial}.$$

- LSM のメリット
 - 計算が高速かつ汎用的: model や商品性によらず、一律に適用できる
 - Data がシンプルになる: 複雑な取引情報を多項式の係数で表現できる
 - Netting が容易: path を発生させなくても、多項式の係数の和で netting できる。
- LSM のデメリット
 - 近似精度の問題

Implicit method

無担保の場合は、Exposure の近似精度の悪さを補う次のような手法がある。

$$\begin{aligned}
 XVA &= E \left[\int_0^T Z(t) \left(\sum_{k \in N_j(c)} V_k(t) \right)^+ dt \right] \\
 &= E \left[\int_0^T Z(t) \left(\sum_{k \in N_j(c)} F_k(t_k, X(t_k)) \right) 1_{\{\sum_{k \in N_j(c)} V_k(t) \geq 0\}} \right] \\
 &\approx E \left[\int_0^T Z(t) \left(\sum_{k \in N_j(c)} F_k(t_k, X(t_k)) \right) 1_{\{\sum_{k \in N_j(c)} \tilde{V}_k(t) \geq 0\}} \right]
 \end{aligned}$$

- Exposure の近似は正負の符号判定のみに用いられる。
- 値がどんなに離れていても符号さえ正しければ、誤差は発生しない。

$$|\hat{c}_1(\omega) - c_0| \leq C_{p,\delta} L^{-\frac{3/2(1-\delta)^2}{2+(1+\delta)(\tilde{N}+1)\ell_0/2}},$$

for any $\omega \in \Omega_L$ and $L \geq 1$. If there exists $\gamma \in (0, 1]$ such that





$$\int_0^T E^\mu[1_{|\sum_{k:T_k \geq t_{i+1}} (P_{T_k-t}^{(k)} F_k)(\pi_k(X(t)))| \leq \theta}] dt = O(\theta^\gamma), \text{ as } \theta \downarrow 0,$$

$$|\hat{c}_2(\omega) - c_0| \leq C_{p,\delta} L^{-\frac{3(\gamma+1)(1-\delta)^2}{(\gamma+2)(2+(1+\delta)(\tilde{N}+1)\ell_0/2)}},$$

特に $\gamma = 1$ の場合、

$$|\hat{c}_1 - c_0| \leq C_{p,\delta} L^{-\frac{3(1-\delta)^2}{2(2+(1+\delta)(N+1)\ell_0/2)}}$$

$$|\hat{c}_2 - c_0| \leq C_{p,\delta} L^{-\frac{3(1-\delta)^2}{2+(1+\delta)(N+1)\ell_0/2}}$$



XVA Greeksの種類

XVA は多くの Market Sensitivity(Greeks) を持っている。

- IR
 - 金利スワップ (JPY 6m roll IRS, 1Y, 2Y, ...)
 - Tenor basis swap (JPY 3m roll IRS, JPY 3m roll IRS, ...)
 - 通貨スワップ (USD LIBOR vs JPY LIBOR + α)
- IR Vol
 - Option 満期 \times Swap Tenor
- FX
- FX Vol
- Inflation Swap, CDS, etc.

基本的には Greeks 計算は有限差分法を使って求める。

$$Greeks(\theta) = \frac{XVA(\theta + \epsilon) - XVA(\theta - \epsilon)}{2\epsilon}$$

XVA Greeks 計算 Technique

愚直に差分を一つ一つ計算する以外に、以下のような Technique が提案されている。

- Freezing method
 - $XVA(\theta + (-)\epsilon)$ を計算する際に、Regression の結果は $XVA(\theta)$ のものを使い回す方法
 - American Option の計算時にはうまくいくらしい。
- Automatic Differentiation
 - 関数を関数を計算する際に、微分も同時に求められるような実装テクニック
 - Neural Network のパラメータにも広く利用されている (Back Propagation)

Freezing 法の検証

- Parameter: $\theta = x_0$ or σ
- model : BS model :
$$dX(t, \theta) = X(t, \theta)(\mu dt + \sigma dW(t)), \quad X(0, \theta) = x_0.$$
- Pay off function : $F(x) = (x - K_1)^+ - K_2$.
- Exposure:

$$V(x, \theta) = E[F(X(T, \theta)) | X(t, \theta) = x] \approx \tilde{V}(x),$$

- Approximated Exposure: $\tilde{V}(x, \theta) \approx V(x, \theta)$
- EPE: $EPE(t) = E[V(X(t))^+]$

この設定の下、Delta $\frac{\partial}{\partial x} EPE(t)$, Vega $\frac{\partial}{\partial \sigma} EPE(t)$, を計算する。

$$Explicit = \frac{\tilde{V}(X(t, \theta + \epsilon), \theta) - \tilde{V}(X(t, \theta - \epsilon), \theta)}{2\epsilon}$$

Explicit 法を用いた Freezing method

Table: Test result of Delta

method	mean	stdev
analytic	5.19	0.13
Non Freezing	5.53	0.13
Freezing	5.22	0.21

Table: Test result of Vega

method	mean	stdev
analytic	1264.77	61.08
Non Freezing	1480.38	74.98
Freezing	522.30	60.15

Delta は Freezing しても誤差はほとんどないが、Vega は Freezing すると誤差がとても大きい

Test 結果の分析 (Explicit 法)

$$\begin{aligned} \frac{\partial}{\partial \theta} E[V(X(t, \theta), \theta)^+] &= E[1_{\{V(X(t, \theta), \theta) \geq 0\}} \frac{\partial}{\partial \theta} V(X(t, \theta), \theta)] \\ &= E[1_{\{V(X(t, \theta), \theta) \geq 0\}} \left(\frac{\partial V}{\partial x_1}(X(t, \theta), \theta) \frac{\partial X(t, \theta)}{\partial \theta} + \frac{\partial V}{\partial x_2}(X(t, \theta), \theta) \right)] \end{aligned}$$

- $\theta = x_0$ の場合、 $\frac{\partial V}{\partial x_2}(X(t, \theta), \theta) = 0$ なので、 θ 変化後に Regression を再度やる必要はなかった。
- $\theta = \sigma$ の場合、 $\frac{\partial V}{\partial x_2}(X(t, \theta), \theta) \neq 0$ なので、 θ 変化後に Regression をやり直さないと大きな誤差が生じる

一般に Markov 過程でモデル化された原資産の初期値パラメータに関する Greeks であれば、Freezing の誤差はないが、そうでない場合は Freezing により誤差が生じうる。

Implicit 法を用いた Freezing method

Table: Test result of Delta

method	mean	stdev
analytic	5.19	0.13
Non Freezing	5.16	0.12
Freezing	5.16	0.12

Table: Test result of Vega

method	mean	stdev
analytic	1264.77	61.08
Non Freezing	1262.38	60.99
Freezing	1262.38	60.99

Implicit method を使った場合、Delta も Vega もうまくいく理由の分析


$$\begin{aligned} \frac{\partial}{\partial \theta} E[F(X(T, \theta)) 1_{\{V(X(t, \theta), \theta) \geq 0\}}] &= E\left[\frac{\partial F}{\partial x}(X(T, \theta)) \frac{\partial X(t, \theta)}{\partial \theta}\right] \\ &+ E[F(X(T, \theta)) \delta_0(V(X(t, \theta), \theta)) \frac{\partial V}{\partial x_2}(X(t, \theta), \theta)] \end{aligned}$$

第二項目が Exposure 関数自体の θ に関する変動を含んだ式になっている。ただし、次のように変形すると 0 になることがわかる。

$$\begin{aligned} (\text{第二項}) &= E[E[F(X(T, \theta)) | \mathcal{F}_t] \delta_0(V(X(t, \theta), \theta)) \frac{\partial V}{\partial x_2}(X(t, \theta), \theta)] \\ &= E[V(X(t, \theta)) \delta_0(V(X(t, \theta), \theta)) \frac{\partial V}{\partial x_2}(X(t, \theta), \theta)] = 0. \end{aligned}$$

Automatic Differentiation の仕組み

- 基本的な関数の合成を計算グラフで表現し、プログラム内にその構造を保持
- 基本的な関数の微分は既知なので、その関数もプログラムしておく
- 最終的に得られる関数は基本関数の合成なので、Tree をたどって、各ノードの微分を掛け合わせて行くことが、Chain rule に対応しており、最終的な Greeks が求められる



$$\frac{dx_4}{dx_1} = D14 + D12 * D24 + D13 * D34$$

XVA 計算における AD のメリット、デメリット

メリット

- 通常の値の計算の数倍（10 未満?）で大量の Greeks 計算が出来る。
- 真の関数の微分を実装しているので、差分法のようなバイアスがない。

デメリット

- 大量のメモリが必要
- On memory で一気通貫で計算しないと厳しい。途中で中間データを出力しながらだと、巨大なヤコビ行列を計算する必要が生じる。
- 途中で滑らかでない関数が入ると一気に依存するポイントの Greeks がおかしくなる
- path ごとの微分を行なっていくので、熱核で積分して滑らかになる要素が含まれていない。

AAD の最近の進展

- Stochastic AAD
- MVA への応用
- ccp